

drugi_zadatak

Fran Lubina, Zvonimir Stracenski, Luka Varga, Karlo Vešligaj

2025-12-17

#Pitanje 2: Postoji li statistički značajna razlika u gradskoj potrošnji automobila između različitih kontinenta proizvođača?

```
grouped <- group_by(my_cars, continent)

summary.result1 <- summarise(
  grouped,
  count = n(),
  mean_city = mean(city.L.100km, na.rm = TRUE),
  median_city = median(city.L.100km, na.rm = TRUE),
  sd_city = sd(city.L.100km, na.rm = TRUE),
  min_city = min(city.L.100km, na.rm = TRUE),
  max_city = max(city.L.100km, na.rm = TRUE),
  q25 = quantile(city.L.100km, 0.25, na.rm = TRUE),
  q75 = quantile(city.L.100km, 0.75, na.rm = TRUE)
)
summary.result1

## # A tibble: 3 x 9
##   continent     count  mean_city median_city  sd_city  min_city  max_city    q25    q75
##   <chr>       <int>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl> <dbl> <dbl>
## 1 Asia          107      9.12      11.5      8.7      2.04      4.8      14.7    7.58
## 2 Europe         74      11.5      11.2      2.48      2.48      6.35      18.1    9.79
## 3 North Ameri~     20      8.46      7.58      2.19      2.19      5        12.4    7.27
# ... with 1 row omitted
```

Tablica prikazuje mjere centralne tendencije gradske potrošnje automobila grupiranih po kontinentu proizvođača. Može se uočiti kako se aritmetička sredina i medijan gradske potrošnje razlikuju među kontinentima.

```
xrange <- range(my_cars$city.L.100km) + c(-0.5, 0.5)
ymax <- max(
  hist(my_cars[my_cars$continent == "Europe", ]$city.L.100km, plot = FALSE)$counts,
  hist(my_cars[my_cars$continent == "Asia", ]$city.L.100km, plot = FALSE)$counts,
  hist(my_cars[my_cars$continent == "North America", ]$city.L.100km, plot = FALSE)$counts
)

par(mfrow = c(1, 3))

hist(my_cars[my_cars$continent == "Europe", ]$city.L.100km,
  main = "Europe",
  xlab = "L/100km",
```

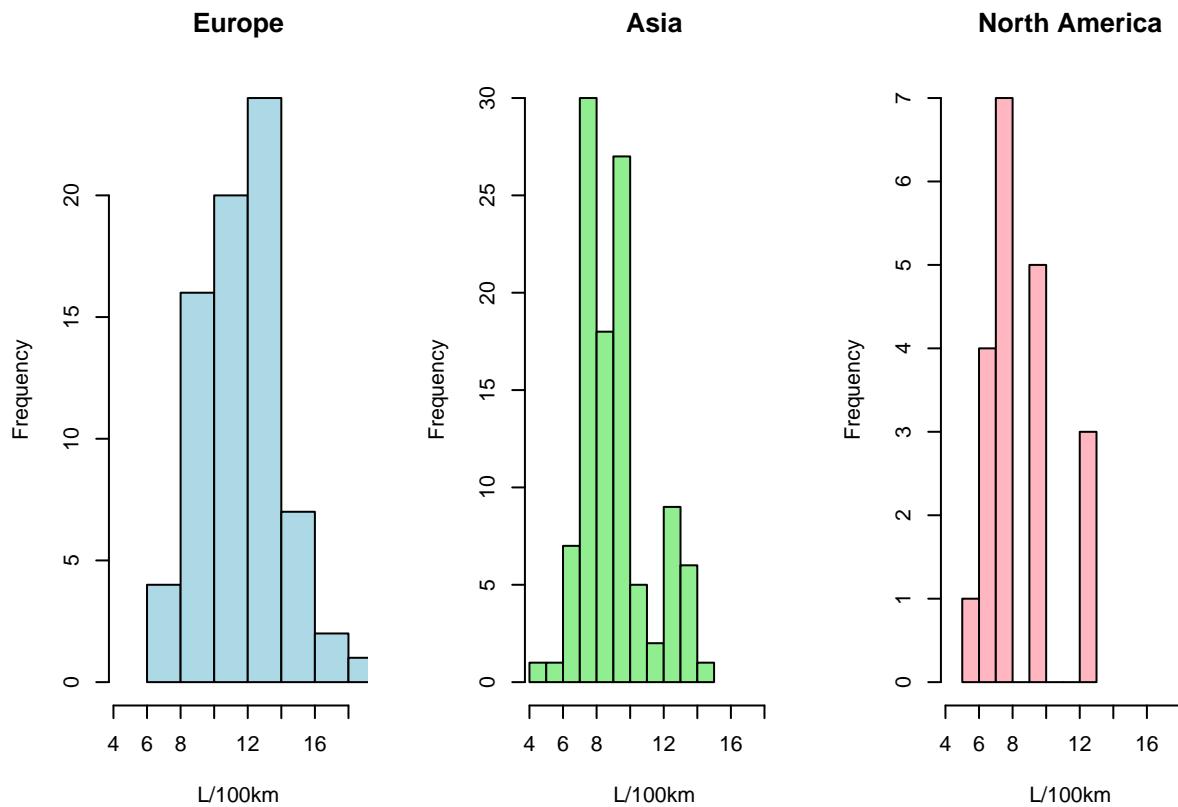
```

ylab = "Frequency",
col = "lightblue",
border = "black",
xlim = xrange)

hist(my_cars[my_cars$continent == "Asia", ]$city.L.100km,
main = "Asia",
xlab = "L/100km",
ylab = "Frequency",
col = "lightgreen",
border = "black",
xlim = xrange)

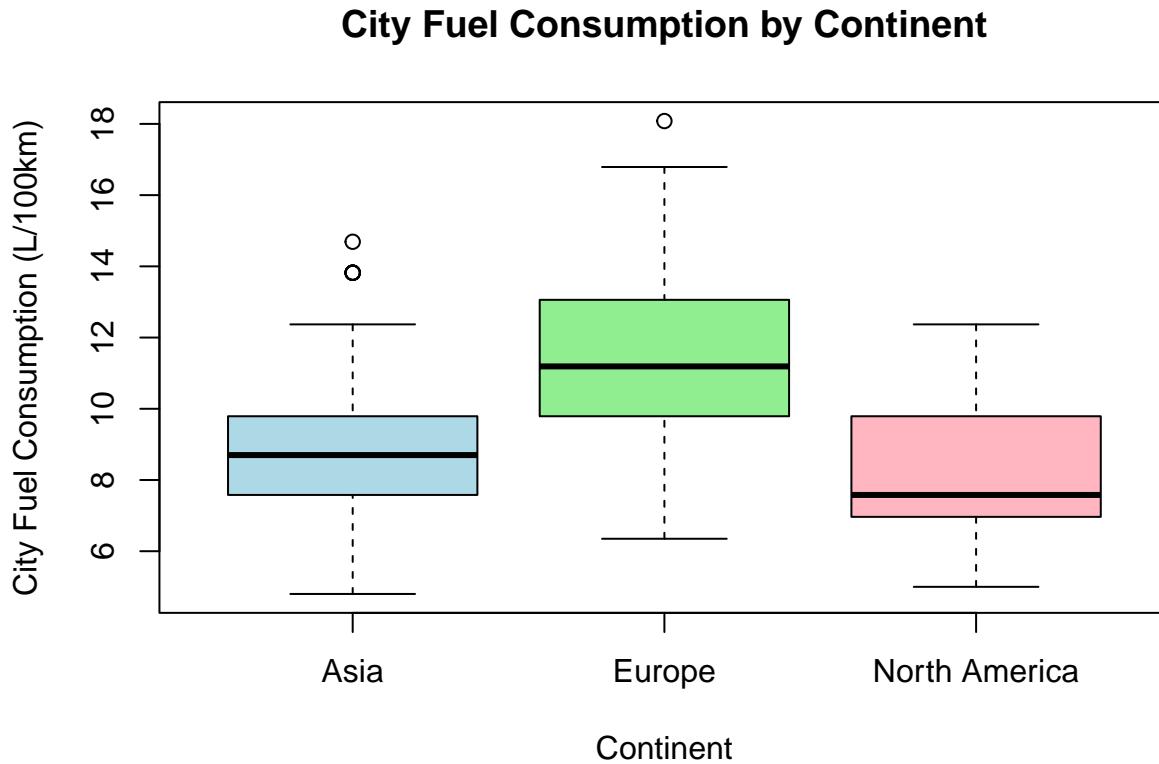
hist(my_cars[my_cars$continent == "North America", ]$city.L.100km,
main = "North America",
xlab = "L/100km",
ylab = "Frequency",
col = "lightpink",
border = "black",
xlim = xrange)

```



Ova tri histograma prikazuju raspodjelu automobila po gradskoj potrošnji, pri čemu svaki histogram predstavlja jedan od kontinenata. Iz prikaza je jasno vidljiva razlika u potrošnji, osobito za Europu, gdje je gradska potrošnja, prema ovom uzorku, znatno viša u odnosu na Sjevernu Ameriku i Aziju.

```
boxplot(city.L.100km ~ continent, data = my_cars,
       main = "City Fuel Consumption by Continent",
       xlab = "Continent",
       ylab = "City Fuel Consumption (L/100km)",
       col = c("lightblue", "lightgreen", "lightpink"))
```



U boxplot dijagramima jasno je vidljiva značajna razlika u medijanima i ostalim kvartalima između kontinenta. Posebno je istaknuta razlika između Europe i preostala dva kontinenta. Europa, prema boxplot dijagramu, ima značajno višu potrošnju. Skoro 75% Europskih automobila iz uzorka ima veću potrošnju od svih Azijatskih i Sjeverno Američkih automobila. U uzorku automobila iz Azije i Europe postoji mali broj stršećih vrijednosti, što može utjecati na raspodjelu podataka, ali ne mijenja osnovni zaključak o razlikama među grupama. Kako bismo izabrali kojim testom možemo testirati postoje li statistički značajna razlika u gradskoj potrošnji automobila između različitih kontinenata proizvodača potrebno je provjeriti normalnost podataka. To je učinjeno sljedećim Q-Q dijagramima.

```
par(mfrow = c(1, 3))

qqnorm(my_cars$city.L.100km[my_cars$continent == "Europe"],
       main = "Q-Q Plot: Europe",
       xlab = "Theoretical Quantiles",
       ylab = "Sample Quantiles")
qqline(my_cars$city.L.100km[my_cars$continent == "Europe"], col = "lightblue")

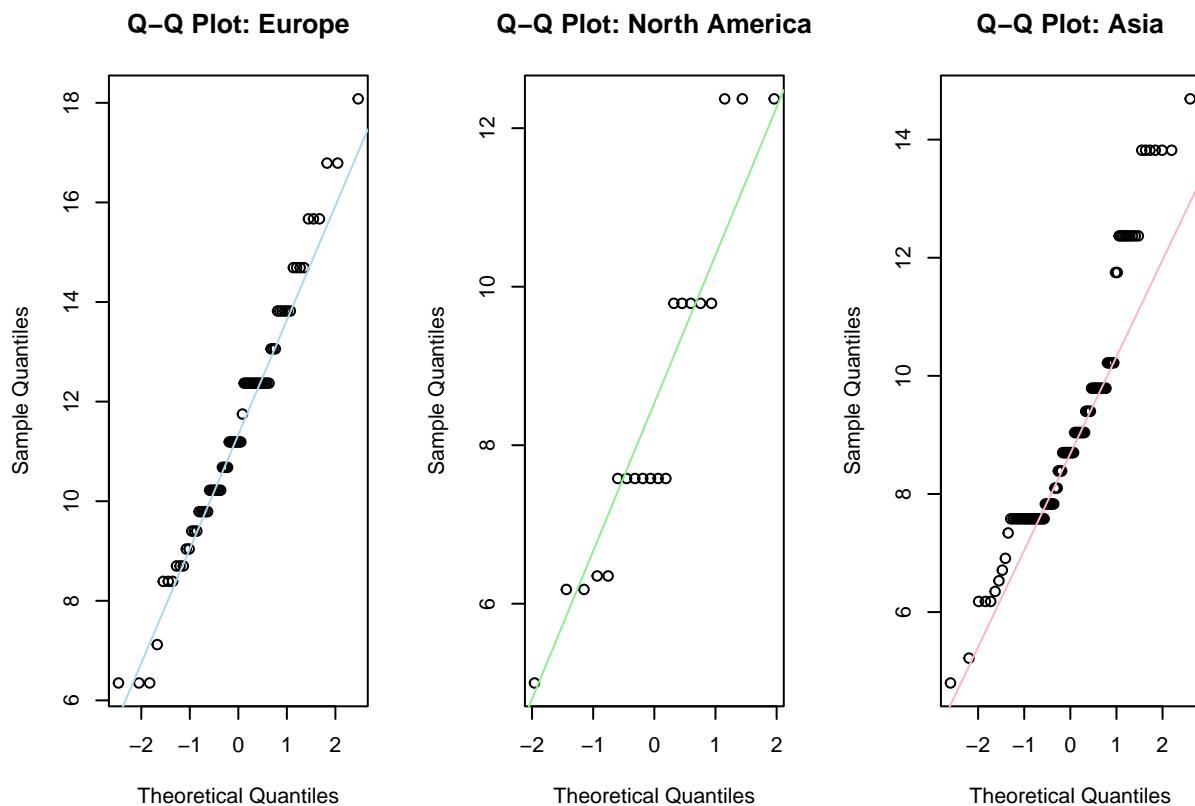
# Q-Q plot for North America
qqnorm(my_cars$city.L.100km[my_cars$continent == "North America"],
       main = "Q-Q Plot: North America",
```

```

    xlab = "Theoretical Quantiles",
    ylab = "Sample Quantiles")
qqline(my_cars$city.L.100km[my_cars$continent == "North America"], col = "lightgreen")

# Q-Q plot for Asia
qqnorm(my_cars$city.L.100km[my_cars$continent == "Asia"],
       main = "Q-Q Plot: Asia",
       xlab = "Theoretical Quantiles",
       ylab = "Sample Quantiles")
qqline(my_cars$city.L.100km[my_cars$continent == "Asia"], col = "lightpink")

```



Q-Q dijagrami prikazuju značajna odstupanja od normalne distribucije za proizvođače iz Sjeverne Amerike i Azije. Zbog toga moramo koristiti test koji ne pretpostavlja normalnost podataka. Zato koristimo Kruskal-Wallisov test koji je neparametarska alternativa ANOVA testu.

```

my_cars$continent <- as.factor(my_cars$continent)
kruskal.test(city.L.100km ~ continent, data = my_cars)

```

```

##
##  Kruskal-Wallis rank sum test
##
##  data:  city.L.100km by continent
##  Kruskal-Wallis chi-squared = 49.079, df = 2, p-value = 2.201e-11

```

Zbog izrazito niske p-vrijednosti Kruskal-Wallisovog testa zaključujemo da ova tri skupa podatka ne proistječu iz iste distribucije, tj. da postoji razlika u gradskoj potrošnji između Azije, Europe i Sjeverne Amerike.

Zbog uočene sličnosti između Azije i Sjeverne Amerike provodimo Wilcoxonov test kako bi usporedili samo ova dva kontinenta.

H0: Ne postoji razlika u gradskoj potrošnji između Azije i Sjeverne Amerike. H1: Postoji razlika u gradskoj potrošnji između Azije i Sjeverne Amerike.

```
wilcox.test(city.L.100km ~ continent,  
            data = subset(my_cars, continent %in% c("Asia", "North America")))
```

```
##  
##  Wilcoxon rank sum test with continuity correction  
##  
## data: city.L.100km by continent  
## W = 1301, p-value = 0.1241  
## alternative hypothesis: true location shift is not equal to 0
```

Rezultati pokazuju p-vrijednost veću od 0.05, što znači da ne odbacujemo H_0 . Zaključujemo da se gradska potrošnja za Aziju i Sjevernu Ameriku vjerojatno ne razlikuje značajno i mogla bi proizlaziti iz iste distribucije.